

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
“ВЫСШАЯ ШКОЛА ЭКОНОМИКИ”
Факультет компьютерных наук
Образовательная программа “Программная инженерия”

СОГЛАСОВАНО

Руководитель курсового проекта, Senior
MLE в Digital Finance International

_____ В.А. Ахмедов
“ ” _____ 2026 г.

УТВЕРЖДАЮ

Академический руководитель
образовательной программы
"Программная инженерия", старший
преподаватель департамента
программной инженерии

_____ Н.А. Павлочев
“ ” _____ 2026 г.

СИСТЕМА ПОИСКА ИНФОРМАЦИИ В ВИДЕОПОТОКАХ ПО
ЕСТЕСТВЕННОМУ ЯЗЫКУ.

Пояснительная записка

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.11.06-01 81 01-1-ЛУ

Исполнитель:

Студент группы БПИ233

_____ / Безруков Г.А. /
“ ” _____ 2026 г.

Подп. и дата	
Инв.№ дубл.	
Взам. инв.№	
Подп. и дата	
Инв.№ подл	

УТВЕРЖДЕН

RU.17701729.11.06-01 81 01-1-ЛЮ

**СИСТЕМА ПОИСКА ИНФОРМАЦИИ В ВИДЕОПОТОКАХ ПО
ЕСТЕСТВЕННОМУ ЯЗЫКУ.**

Пояснительная записка

RU.17701729.11.06-01 81 01-1

Листов 11

Инв.№ подл	Подп. и дата	Взам. инв.№	Инв.№ дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. ВВЕДЕНИЕ	3
1.1. Наименование программы	3
1.2. Документы, на основании которых ведётся разработка	3
2. НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ	4
2.1. Основное назначение	4
3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ	5
3.1. Постановка задачи	5
3.2. Описание выбранного алгоритма	5
3.3. Архитектура системы	6
3.4. Обоснование выбора технологий	7
3.5. Исследовательская часть	7
3.6. Обоснование выбора метода реализации	9
4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ	10
4.1. Эффективность разработки	10
4.2. Сравнение с аналогами	10
ИСТОЧНИКИ, ИСПОЛЬЗОВАННЫЕ ПРИ РАЗРАБОТКЕ	11

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. ВВЕДЕНИЕ

1.1. Наименование программы

Наименование программы – “Система поиска информации в видеопотоках по естественному языку”.

Наименование программы на английском языке – “Natural Language Video Search System”.

1.2. Документы, на основании которых ведётся разработка

Учебный план подготовки бакалавров по направлению 09.03.04 “Программная инженерия” НИУ ВШЭ и утверждённая академическим руководителем программы тема курсового проекта.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ

2.1. Основное назначение

Программная система “Система поиска информации в видеопотоках по естественному языку” предназначена для автоматизированного поиска информации в видеоархивах систем видеонаблюдения по запросам пользователя на естественном языке и по фотоизображениям. Система обеспечивает диалоговое взаимодействие с пользователем, разрешение неоднозначных сущностей через интерактивный выбор, сохранение истории переписки и интеграцию с внешней системой видеонаблюдения как источником видеоматериалов и аналитических событий.

Область применения системы включает службы безопасности и видеонаблюдения, аналитические подразделения организаций, исследовательские группы в области компьютерного зрения и обработки естественного языка, а также организации, эксплуатирующие системы управления видеонаблюдением и заинтересованные в семантическом поиске по аналитическим событиям без замены существующего видеохранилища.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ

3.1. Постановка задачи

Требуется разработать программную систему с веб-интерфейсом, которая:

1. обеспечивает регистрацию и авторизацию пользователей с защищённым хранением учётных данных и поддерживает удаление аккаунта пользователя;
2. позволяет создавать чат-сессии и вести в них диалог с системой;
3. принимает на вход текстовые запросы на естественном языке и/или фотоизображения лиц;
4. интерпретирует запрос с помощью большой языковой модели и приводит его к структурированному представлению;
5. выполняет семантический поиск именованных сущностей (фамилий, адресов, номерных знаков) в векторной базе данных;
6. запрашивает у пользователя уточнение неоднозначных сущностей через интерактивный выбор кандидатов;
7. выполняет поиск событий с заданным лицом, формируя дескриптор лица через внешнюю систему видеонаблюдения;
8. обращается к внешней VMS за видеоаналитическими событиями, соответствующими интерпретированному запросу, и формирует ответ с превью событий и глубокими ссылками на видеосегменты;
9. отображает результаты пользователю в потоковом режиме с индикацией стадий обработки;
10. сохраняет историю чат-сессий и обеспечивает возможность их просмотра и удаления.

3.2. Описание выбранного алгоритма

Решение реализуется как стейтфул-агент на базе фреймворка LangGraph. Граф состоит из нескольких узлов и условных переходов, организующих обработку запроса пользователя.

Этапы обработки:

1. **Маршрутизация на входе.** По наличие текста и/или фотоизображения определяется начальный узел графа. Запросы только с фотоизображением направляются непосредственно на разрешение лица; запросы с текстом начинаются с парсинга.
2. **Парсинг запроса.** Большая языковая модель в режиме структурированного вывода приводит исходный текстовый запрос к одной из предметных схем: запрос о людях (PeopleQuerySchema), запрос о транспортных средствах (VehiclesQuerySchema) или общий запрос (AllQuerySchema). Схемы содержат поля для именованных сущностей (фамилии, адреса, номерные знаки), временного диапазона, этажей, атрибутов внешности и характеристик транспорта.
3. **Разрешение именованных сущностей.** Для каждой именованной сущности выполняется поиск кандидатов в векторной базе данных Qdrant по эмбедингам, полученным через сервис Text Embeddings Inference (модель multilingual-e5-base). При обнаружении неоднозначности граф приостанавливается через механизм LangGraph interrupt, и пользователь выбирает подходящих

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- кандидатов из предложенного списка. После получения выбора граф возобновляется через `Command(resume=...)`.
4. **Разрешение лица по фотоизображению.** Если в запросе присутствует фото, оно сохраняется в объектном хранилище MinIO; внешняя VMS формирует векторный дескриптор лица. По дескриптору в VMS выполняется поиск зарегистрированных лиц-кандидатов, после чего пользователю предлагается уточнить выбор аналогично разрешению именованных сущностей.
 5. **Формирование запроса к VMS.** На основе разрешённых сущностей и фильтров (временной диапазон, атрибуты, координаты) формируется объект `EventFilter` для запроса видеоаналитических событий из внешней системы видеонаблюдения.
 6. **Получение событий и формирование ответа.** По сформированному фильтру выполняется запрос к VMS API; результат включает список событий с временными метками, идентификаторами и снимками. На основе полученных данных большая языковая модель формирует естественно-языковой ответ пользователю; параллельно формируется глубокая ссылка на интерфейс VMS и список превью событий для отображения в карточках.
 7. **Потоковый вывод результата.** Промежуточные стадии графа, токены ответа модели и итоговые превью передаются клиенту через Server-Sent Events. История переписки сохраняется в реляционной базе данных.

3.3. Архитектура системы

Программная система реализована как набор взаимодействующих сервисов, разворачиваемых в контейнерах Docker:

- **Frontend** (Vue 3 + TypeScript + Vite) – одностраничное веб-приложение, обеспечивающее пользовательский интерфейс и работу с потоковыми событиями SSE;
- **Backend** (Python + FastAPI + LangGraph) – основная серверная логика: авторизация, чат-сессии, LangGraph-агент диалогового поиска, проксирование медиа из VMS;
- **AI-сервис** (Python + FastAPI) – унифицированный шлюз к моделям машинного обучения: проксирование запросов к vLLM (или OpenRouter) для большой языковой модели и к Hugging Face TEI для текстовых эмбеддингов;
- **vLLM** – инференс большой языковой модели Qwen3-8B с OpenAI-совместимым API; разворачивается отдельно от docker-compose проекта (на выделенном GPU-узле), AI-сервис обращается к нему по адресу, заданному в переменной окружения `VLLM_URL`. Альтернативно поддерживается провайдер OpenRouter с тем же OpenAI-совместимым интерфейсом;
- **TEI** – инференс модели текстовых эмбеддингов `multilingual-e5-base`;
- **PostgreSQL** – хранение пользовательских аккаунтов, чат-сессий, сообщений, контрольных точек LangGraph;
- **Qdrant** – векторная база данных для семантического поиска именованных сущностей;
- **Redis** – кеш и список отозванных JWT-токенов;
- **MinIO** – объектное хранилище для фотоизображений, прикрепленных к сообщениям чата;

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- **VMS API** – внешняя система видеонаблюдения, предоставляющая видеоаналитические события, дескрипторы лиц и снимки.

Взаимодействие между компонентами осуществляется по протоколу HTTP(S). Клиентская часть взаимодействует с сервером по HTTP/SSE; серверные компоненты обращаются друг к другу и к внешней VMS по HTTP. Конфигурация всех сервисов задаётся через переменные окружения и шифруется в репозитории с использованием SOPS и age.

3.4. Обоснование выбора технологий

Python 3.11 и FastAPI. Python является де-факто стандартом для машинного обучения и обработки естественного языка; FastAPI обеспечивает асинхронную обработку запросов, автоматическую генерацию OpenAPI-документации и типобезопасность через Pydantic.

LangGraph. Фреймворк позволяет описывать пайплайны диалоговых агентов в виде графа состояний с поддержкой контрольных точек и механизма прерывания (interrupt/resume), необходимого для интерактивного уточнения неоднозначных сущностей.

Qwen3-8B + vLLM. Большая языковая модель открытого выпуска с поддержкой структурированного вывода и качественным русским языком. vLLM обеспечивает высокопроизводительный инференс с OpenAI-совместимым API, что упрощает интеграцию.

Multilingual-E5 + TEI. Модель multilingual-e5-base поддерживает русский и английский языки, что соответствует характеру именованных сущностей предметной области. Hugging Face TEI обеспечивает удобный HTTP-интерфейс к модели, поддержку батчинга и кэширования.

Qdrant. Векторная база данных с поддержкой полей метаданных и фильтров, масштабируется до миллионов сущностей; используется для хранения эмбеддингов имён, адресов и номерных знаков.

PostgreSQL. Надёжная реляционная СУБД для хранения структурированных данных (пользователи, чат-сессии, сообщения) и контрольных точек LangGraph.

Redis. Используется как кеш и для реализации списка отозванных JWT-токенов.

MinIO. Объектное хранилище, совместимое с S3 API, для хранения фотоизображений из сообщений чата.

Vue 3 и TypeScript. Современный фреймворк для построения одностраничных приложений с реактивной моделью данных, удобной поддержкой Server-Sent Events и строгой типизацией.

Docker Compose + SOPS + age. Контейнеризация упрощает разворачивание многокомпонентной системы; SOPS совместно с age обеспечивает шифрование секретов в репозитории.

3.5. Исследовательская часть

В рамках работы проведено отдельное исследование методов поиска видеомоментов по текстовым запросам как направление дальнейшего развития системы (полная индексация видеоматериалов

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

средствами проекта). Исследование проведено в форме набора Jupyter-ноутбуков на открытом бенчмарке **QVHighlights** (10 500 видео, аннотации видеомоментов под текстовые запросы).

Сравнивались следующие модели и стратегии индексации:

- **CLIP ViT-L/14** (poolings: пофреймовый и оконный);
- **X-CLIP** (оконная индексация);
- **CG-DETR** (стратегии прямой локализации и cross-encoder saliency);
- **Qwen3-VL-Embedding-2B** и **Qwen3-VL-Embedding-8B** (различные размеры окна и шага индексации, в том числе с применением реранкера Qwen3-VL-Reranker-2B).

Метрики оценки: средний IoU (mean_iou, mean_iou@top1, mean_iou@top5), Video Recall@K, Moment Recall@K@IoU{0.3, 0.5, 0.7}, Moment MRR@IoU, Video MRR, Video mAP, nDCG@K.

Таблица 1 – Сводные результаты сравнения моделей retrieval (выборочно)

Модель / стратегия	mean_iou@top1	Video Recall@1	MR@IoU≥0.5	Moment MRR@IoU0.5	Video mAP
CG-DETR / direct	0.865	0.636	0.570	0.164	0.169
CG-DETR / saliency	0.602	0.860	0.589	0.400	0.582
Qwen3-VL-8B / w2s1	0.606	0.953	0.673	0.553	0.648
Qwen3-VL-8B / w4s1	0.574	0.953	0.673	0.533	0.676
Qwen3-VL-8B / frame	0.603	0.916	0.636	0.531	0.595
Qwen3-VL-2B / w2s2	0.611	0.944	0.645	0.508	0.564
CLIP ViT-L/14 / window	0.559	0.935	0.542	0.350	0.455
CLIP ViT-L/14 / frame	0.448	0.907	0.383	0.271	0.434
X-CLIP / window	0.452	0.664	0.215	0.136	0.243

Выводы по результатам исследования:

- Наилучший результат по mean_iou@top1 показывает модель **CG-DETR** в режиме прямой локализации (direct), но она существенно проигрывает по полноте видеоретрива (Video Recall@1 = 0.636), так как направлена на точечное предсказание границ момента;
- Модели на базе **Qwen3-VL-Embedding-8B** при оконной индексации с малым шагом дают лучший баланс точности и полноты: Video Recall@1 достигает 0.953, Moment Recall@1@IoU≥0.5 = 0.673;
- **CLIP ViT-L/14** в оконной стратегии демонстрирует приемлемый результат при значительно меньшей вычислительной стоимости и пригоден в качестве baseline;
- **X-CLIP** в текущей конфигурации проигрывает по всем метрикам и не рекомендуется к использованию в рассматриваемой задаче.

Полученные результаты позволяют обоснованно выбирать модель индексации видео для последующего расширения системы за пределы интеграции с внешней VMS – в направлении самостоятельной индексации видеоархивов и поиска видеомоментов по текстовым запросам.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3.6. Обоснование выбора метода реализации

Разработанная архитектура опирается на интеграцию с внешней системой видеонаблюдения как источником видеоматериалов и заранее извлечённых аналитических событий. Такой подход обоснован следующими факторами:

- **Использование структурированных метаданных VMS.** Внешняя VMS уже формирует структурированные события (детекции лиц, номерных знаков, объектов) с привязкой к камере, времени и снимкам. Опора на эти метаданные позволяет ускорить разработку и обеспечить высокую точность поиска без необходимости самостоятельной индексации сырых видеопотоков.
- **Снижение вычислительной нагрузки.** Самостоятельная индексация полнообъёмного видеоархива требует значительных вычислительных ресурсов и времени; в условиях курсового проекта такой подход не обеспечил бы практической применимости системы.
- **Поддержка существующей инфраструктуры заказчика.** Заказчик эксплуатирует VMS, и интеграция с ней позволяет использовать систему как надстройку над существующей инфраструктурой без её замены.
- **Возможность расширения.** Параллельно проведённое исследование retrieval-моделей на бенчмарке QVHighlights закладывает основу для будущего расширения системы в направлении самостоятельной индексации видеомоментов.

Выбор LangGraph как фреймворка диалогового агента обоснован необходимостью поддержки прерываний и возобновления графа при интерактивном уточнении неоднозначных сущностей, а также удобством управления стейтом и логированием стадий обработки. Альтернативные подходы (прямые цепочки промптов, ReAct-агенты на базе функциональных вызовов) не обеспечивают аналогичной структурированности и удобства отладки.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4. ОЖИДАЕМЫЕ ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ

4.1. Эффективность разработки

Оценка эффективности носит ориентировочный характер и приведена для типового сценария поиска информации в видеоархиве организации. Использование разработанной системы позволяет сократить время поиска информации в видеоматериалах с десятков минут ручного просмотра записей до секунд диалогового запроса на естественном языке.

Эффект достигается за счёт:

- интерпретации запроса на естественном языке без необходимости точного формулирования критериев поиска;
- семантического поиска именованных сущностей по векторной базе данных вместо точного совпадения;
- использования заранее сформированных видеоаналитических событий VMS вместо последовательного просмотра видеопотоков;
- поддержки поиска по фотоизображению, расширяющего область применения за пределы текстовых запросов.

Для случаев со сложной формулировкой запроса предусмотрен интерактивный механизм уточнения неоднозначных сущностей, что позволяет получать релевантные результаты даже при неполных или неоднозначных запросах.

4.2. Сравнение с аналогами

Сравнительная характеристика разработанной системы с отечественными и зарубежными аналогами (Google Video Intelligence, AWS Rekognition Video, BriefCam, Azure Video Indexer) приведена в Приложении 2 Технического задания. Совокупность реализованных функций – семантический поиск по событиям видеоархива, диалоговый интерфейс с историей чатов, поиск по фотоизображению, локальное развёртывание на инфраструктуре заказчика и поддержка русского языка – отличает разрабатываемую систему от существующих решений.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ИСТОЧНИКИ, ИСПОЛЬЗОВАННЫЕ ПРИ РАЗРАБОТКЕ

1. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению.
2. ГОСТ 19.101-77: Виды программ и программных документов.
3. ГОСТ 19.201-78: Техническое задание. Требования к содержанию и оформлению.
4. ГОСТ 19.301-79: Программа и методика испытаний. Требования к содержанию и оформлению.
5. Lei J., Berg T. L., Bansal M. QVHighlights: Detecting Moments and Highlights in Videos via Natural Language Queries. NeurIPS, 2021.
6. Radford A. et al. Learning Transferable Visual Models From Natural Language Supervision (CLIP). ICML, 2021.
7. Ni B. et al. Expanding Language-Image Pretrained Models for General Video Recognition (X-CLIP). ECCV, 2022.
8. Moon W. et al. Correlation-Guided Query-Dependency Calibration for Video Temporal Grounding (CG-DETR). 2023.
9. Документация FastAPI: <https://fastapi.tiangolo.com/>
10. Документация LangGraph: <https://langchain-ai.github.io/langgraph/>
11. Документация Vue 3: <https://vuejs.org/guide/introduction.html>
12. Документация Qdrant: <https://qdrant.tech/documentation/>
13. Документация vLLM: <https://docs.vllm.ai/>
14. Документация Text Embeddings Inference: <https://huggingface.co/docs/text-embeddings-inference>
15. Документация Qwen3: <https://qwen.readthedocs.io/>
16. QVHighlights Benchmark: https://github.com/jayleicn/moment_dettr
17. Radford A. et al. Learning Transferable Visual Models From Natural Language Supervision (CLIP). 2021.
18. Ni B. et al. Expanding Language-Image Pretrained Models for General Video Recognition (X-CLIP). 2022.
19. Moon W. et al. Correlation-Guided Query-Dependency Calibration in Video Representation Learning for Temporal Grounding (CG-DETR). 2023.
20. Документация Docker и Docker Compose: <https://docs.docker.com/>
21. Документация PostgreSQL: <https://www.postgresql.org/docs/>
22. Документация Redis: <https://redis.io/documentation>
23. Документация MinIO: <https://min.io/docs/minio/linux/index.html>

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.11.06-01 81 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата